

利用高效脉冲触发近似训练扩展脉冲驱动型 Transformer

姚曼*、邱雪瑞*、胡天翔、胡家奎、仇宇红、田克宇、廖建兴、冷路子伟、徐博和李国奇

摘要——类脑脉冲神经网络 (SNN) 的目标是成为传统人工神经网络 (ANN) 的低功耗替代方案。本文旨在解决实现这一愿景的两大挑战：SNN 与 ANN 之间的性能差距以及 SNN 的高昂训练成本。我们识别出脉冲神经元由二元放电机制导致的固有缺陷，并提出了一种基于整数训练和脉冲驱动推理的脉冲放电近似 (SFA) 方法。该方法优化了脉冲神经元的脉冲放电模式，从而提高了训练效率，降低了功耗，提升了性能，简化了扩展，并更好地利用了神经形态芯片。此外，我们还开发了一种高效的脉冲驱动 Transformer 架构和脉冲掩码自编码器，以防止 SNN 在扩展过程中出现性能下降。在 ImageNet-1k 数据集上，我们分别使用包含 1000 万、1900 万、8300 万和 1.73 亿参数的模型，实现了 78.5%、79.8%、84.0% 和 86.2% 的最先进 top-1 准确率。例如，1000 万参数的模型在 ImageNet 上比现有最佳 SNN 模型性能提升了 7.2%，同时还提高了训练速度和推理能耗。

性能分别提升了 4.5 倍和 3.9 倍。我们验证了所提出方法在目标检测、语义分割和神经形态视觉等多种任务中的有效性和效率。这项工作使脉冲神经网络 (SNN) 能够在保持低功耗优势的同时达到与人工神经网络 (ANN) 相当的性能，标志着 SNN 作为通用视觉骨干网络迈出了重要一步。代码可在 Spike-driven Transformer V3 中找到。

索引词——脉冲神经网络、脉冲驱动、脉冲变换器、神经形态计算、高效架构和训练



1 介绍

脉冲神经网络 (SNN) 因其受大脑启发的时空动态特性和脉冲驱动的高效计算范式而备受关注[1][2]。脉冲神经元通过二进制脉冲进行通信，遵循“积分-发放”动态模型[3]。脉冲神经元将空间和时间信息整合到膜电位中。当膜电位超过某个阈值时，神经元发出脉冲，膜电位根据特定规则重置。神经形态芯片[4][5][6]使用脉冲神经元和突触作为基本计算单元，在硬件电路上实现 SNN。神经形态计算的脉冲驱动特性使得 SNN 仅在信号存在时才触发稀疏加法运算，与传统的人工神经网络 (ANN) 相比，具有显著的能效优势。这种低功耗优势在小规模边缘计算场景中尤为明显[7][8][9]。例如，最近推出的异步感知计算神经形态片上系统 (SoC) Speck [10] 的静态功耗仅为 0.42mW，其在典型神经系统中的运行功耗也仅为 0.42mW。

形态视觉应用功率范围为 0.7 至 15 mW。

在深度学习时代，模型规模对于现代机器学习的成功至关重要。脉冲神经网络 (SNN) 也在不断扩展。大规模 SNN 的训练方法主要有两种：ANN2SNN 和直接训练。ANN2SNN 使用脉冲发放率来近似人工神经网络 (ANN) 的激活值，虽然精度相近，但需要大量的推理时间步，并且忽略了时空动态特性[11]、[12]、[13]、[14]、[15]。直接训练将脉冲神经元的非线性微分方程转化为离散可迭代的形式，并利用时空反向传播 (STBP) 和代理梯度进行训练[16]、[17]。这种方法在架构设计上提供了灵活性，并利用了脉冲神经元的时空动态特性[18]、[19]、[20]、[21]、[22]、[23]、[24]，但多时间步模拟需要大量的计算资源。例如，直接训练一个具有 10 个时间步长的脉冲 ResNet-19 需要比传统 ResNet-19 多大约 20 倍的内存 [25]。

在扩展脉冲神经网络 (SNN) 性能的过程中，当前的训练方法面临着一个悖论。延长时间步长可以减少将膜电位量化为脉冲的误差，从而确保更好的任务性能。然而，多时间步长模拟需要大量的 GPU 内存，并且训练难度也大大增加，这阻碍了 SNN 的可扩展性和性能提升。

现有观点认为，将连续膜电位转换为脉冲会导致量化误差[26]。我们通过证明二进制放电是一种根本性的机制缺陷，也是悖论的根源，从而扩展了这种理解。脉冲放电的二进制特性会削弱放电神经元评估传入信号重要性（空间表征）的能力，并且

- M. Yao、X. Qiu、T. Hu、B. Xu 和 G. Li 均来自中国科学院自动化研究所，北京，中国。
- X. Qiu 同时也是中国科学院大学未来技术学院的成员，工作地点位于中国北京。
- J. Hu 和 K. Tian 均来自中国北京大学人工智能研究所。
- 周先生就职于中国香港香港理工大学计算机系。
- J. Liao 和 L. Leng 均来自中国广东省深圳华为 ACS 实验室。

* 同等贡献。

† 通讯作者: 李国琪 (E-mail: guoqi.li@ia.ac.cn).

arXiv:2411.16061v1[cs.CV] 2024 年 11 月 25 日

脉冲发放的二元特性削弱了脉冲神经元评估输入信号重要性的能力（空间表征），并限制了其记忆和遗忘能力（时间动态）。目前的方法，包括 ANN2SNN 和直接训练，试图通过速率编码来解决空间表征问题[27]，但训练效率仍然低下，且无法克服时间动态的限制。

我们提出了一种简单的脉冲发放近似（SFA）方法来解决这些缺陷。具体来说，SFA 在训练过程中使用整数作为激活值，然后在推理过程中将其转换为脉冲序列。这导致其脉冲发放模式与 ANN2SNN 和直接训练截然不同。与后两者的同步随机发放不同，SFA 的发放模式是异步且连续的。我们证明，这种发放模式显著影响训练、推理能力、性能、网络扩展性和神经形态芯片的实现。在所有这些方面，SFA 方法均优于 ANN2SNN 和直接训练。

接下来，我们着重通过架构设计和模型规模扩展来进一步提升脉冲神经网络（SNN）的性能上限。Meta-SpikeFormer [28] 研究了基于脉冲驱动 Transformer [29] 的 SNN 架构的元设计，首次将脉冲驱动范式融入 Transformer。我们对 Meta-SpikeFormer 进行了升级，包括改进卷积和脉冲驱动自注意力算子等。我们提出的高效脉冲 Transformer（E-SpikeFormer）能够同时提升性能和能效。为了解决 E-SpikeFormer 在规模扩展时性能下降的问题，我们设计了一种脉冲稀疏卷积，并将其与掩码图像建模（MIM）[30]、[31] 预训练策略相结合。

本文提出的方法在静态图像分类（ImageNet-1k [32]）、目标检测（COCO [33]）、语义分割（ADE20K [34]）和神经形态动作识别（HAR-DVS [35]）任务上均得到了验证。我们扩展了 SNN 的性能，并在所有测试数据集上都取得了最先进的结果。我们的主要贡献如下：

- 脉冲神经元机制分析：我们发现二元脉冲发放是一种机制缺陷，它影响脉冲神经元的空间表征和时间动态。
- 脉冲发放近似法（SFA）：本文提出的 SFA 方法利用了基于整数的训练和脉冲序列推理之间的等价性。我们证明，SFA 通过调整脉冲神经元的脉冲发放模式，能够同时优化脉冲神经网络（SNN）的训练、能效、性能和扩展性。此外，我们还讨论了 SFA 在神经形态芯片上的实现。
- 高效的架构设计：我们引入了 ESpikeFormer，它基于先前最先进的 SNN，通过设计高效的脉冲驱动卷积和自注意力算子，实现了更高的准确率和更低的能量成本。
- 扩展 SNN。我们结合脉冲稀疏卷积和 MIM 预训练来解决扩展 SNN 时性能下降的问题。
- 提升 SNN 的性能上限：我们证明，在各种视觉任务中，SNN 可以达到与 ANN 相当的性能。




图 1: E-SpikeFormer 与其他脉冲变换器在 ImageNet-1k 上以 224 输入空间分辨率进行比较。

更低的能耗，凸显了它们作为通用低功耗视觉主干的潜力。

本文余下部分组织如下：第 2 节回顾相关工作；第 3 节介绍我们的方法；第 4 节分析 SFA 方法；第 5 节在静态和神经形态视觉数据集上验证我们方法的有效性和效率；第 6 节讨论所提出方法在神经形态芯片上的实现。

第 7 节总结了这项工作。

2 预赛

脉冲神经网络（SNN）的高效训练。复杂的时空动态特性使得 SNN 的训练成本自然高于人工神经网络（ANN）。多时间步模拟需要 $O(L \times T)$ 的内存来进行 STBP 训练，其中 L 为层数， T 为时间步长。高效 SNN 训练的根本逻辑在于将训练内存与时间步长 T 解耦。例如，基于梯度重要性分析，仅保留 SNN 的空间梯度[36][37]；在单个时间步长上进行预训练，然后将模型微调至多个时间步长[28][38]；采用时间或空间可逆设计来降低内存使用量[39][40]；根据样本难度动态减少训练和推理过程中的时间步长[41][42]。这些方法在技术上有效地缓解了大规模 SNN 的训练难题，但却忽略了一个根本问题：为什么 SNN 在静态任务中需要采用多时间步模拟？”本文对该问题进行了深入分析，并提出了解决方案。

频谱网络架构设计。频谱网络的主要主题

深度学习时代正在加速规模化。架构设计是实现这一目标的重要技术途径之一。早期的研究主要集中在 Spiking ResNet 设计上。直接将 ResNet [43] 的残差连接复制到 SNN [19] 中被证明无法实现恒等映射 [44]，因此仍然存在性能下降的问题。为了解决这个问题，SEW-ResNet [18] 和 MS-ResNet [45] 通过在 SNN 和 ResNet [43] 之间创建捷径，成功地将 SNN 的深度扩展到了数百层。

为了解决这个问题，我们分别考虑了不同层之间的脉冲和膜电位。相比之下，近期将脉冲神经网络（SNN）和 Transformer 相结合的研究[46][47]主要集中在如何设计脉冲驱动的自注意力机制上。早期的脉冲 Transformer[48][49][50]均无法实现脉冲驱动。直到脉冲驱动 Transformer[29]出现，才首次仅使用加法和掩码操作实现了脉冲驱动的自注意力，从而在脉冲 Transformer 中实现了稀疏加法。脉冲驱动 Transformer v2（即 Meta-SpikeFormer[28]）探索了 SNN 的元设计[51][52]，并讨论了其对神经形态芯片设计的潜在影响。本文进一步优化了 Meta-SpikeFormer 中的冗余设计，以更少的参数和功耗实现更高的性能。

掩码图像建模（MIM）[30] 是一种自……

监督学习策略能够有效提升视觉模型的规模。受自然语言处理（NLP）中掩码预训练微调语言模型[53]的启发，BEiT[54]率先将掩码信息模型（MIM）集成到视觉领域，通过训练来预测视觉标记。随后，著名的 MAE[30]引入了一种非对称编码器-解码器架构，绕过了计算密集型编码器中的掩码标记，所有标记都通过轻量级解码器进行处理。MAE 式的预训练有助于 Vision Transformer（ViT）增强其对局部偏差的适应能力，并克服其性能下降的问题[30],[55],[56]。MAE 式的预训练也有助于 CNN 或 CNN+ViT 混合架构的扩展，但这需要对训练策略进行调整。例如，MC-MAE [57]、Convnext v2 [58] 和 Spark [31] 都采用了掩码卷积或稀疏卷积来防止信息泄露，并协调预训练和微调之间的差异。由于我们遵循 [28] 中 SNN 的元架构设计，并且元 SNN 是 Conv+ViT 的混合形式，因此我们借鉴了 [31]、[57] 和 [58] 中的混合 MIM 框架来实现 E-SpikeFormer 的大规模预训练。

3 种方法

我们在第 3.1 节中介绍和分析脉冲神经元模型。然后，我们分别在第 3.2 节、第 3.3 节和第 3.4 节中提出新的训练方法、E-SpikeFormer 架构和 MIM 策略来扩展 SNN。

3.1 脉冲神经元

3.1.1 集成、触发和复位机制

脉冲神经元的时空动力学和脉冲通信是从生物神经元中抽象出来的[3]。由于生物神经元动力学的计算复杂度很高，现有的脉冲神经元被简化为微分方程，以方便计算机模拟。通过求解微分方程，可以得到脉冲神经元的迭代版本[16]，[59]：

$$U[t] = \beta H[t-1] + X[t], \quad (1)$$

$$S[t] = \text{Hea}(U[t] - V), \quad (2)$$

$$H[t] = \begin{cases} U[t] \cdot (1 - S[t]) + V \cdot S[t], & \text{硬重置,} \\ U[t] - V \cdot S[t], & \text{软重启,} \end{cases} \quad (3)$$

其中 t 为时间步长， $U[t]$ 表示膜充电后、放电前的膜电位。

空间输入 $X[t]$ 通过卷积或多层感知器（MLP）操作从原始脉冲输入中提取，时间输入 $\beta H[t-1]$ 由前一时间步膜电位的衰减导出， β 为衰减（泄漏）因子， $S[t]$ 为输出脉冲， $H[t]$ 为放电后的膜电位， $\text{Hea}(\cdot)$ 为 Heaviside 函数，当 $x \geq 0$ 时 $\text{Hea}(x) = 1$ 。当 $U[t]$ 超过阈值 V 时，脉冲神经元将发出脉冲，膜电位重置为 V 。

式（1）、式（2）、式（3）分别表示脉冲神经元的积分机制、放电机制和重置机制：

i) 整合定义了时空信息的融合方式。例如，在使用硬重置时，在整合-发放（IF）神经元 [60] 中， $\beta = 1$ ；而在漏积分-发放（LIF）神经元 [3] 中， $\beta < 1$ 。因此，LIF 和 IF 对先前时间步信息的记忆方式不同。

ii) 脉冲神经网络（SNN）中信息的传递方式由神经元放电机制决定。脉冲神经元仅在膜电位超过阈值时才会发出二进制脉冲。因此，SNN 可以享受事件（脉冲）驱动带来的低功耗特性，这意味着网络仅在输入时才触发稀疏加法运算 [29]，[61]。

iii) 重置机制定义了脉冲神经元如何记忆和遗忘（图 2）。我们讨论三种重置机制：无重置 [62]、硬重置 [3] 和软重置 [60]。无重置和硬重置代表两种极端情况。前者会记住所有信息，导致神经元无限放电。后者会在神经元发出脉冲后（如果 $V=0$ ）遗忘所有已有信息。软重置是一种介于无重置和硬重置之间的折衷方案，它在神经元发出脉冲后从膜电位中减去 V 的同时，保留部分信息。

3.1.2 二进制尖峰触发的固有缺陷

脉冲神经元模型通常由其整合和重置机制定义。基于公式（1）和公式（3），可以识别出四种类型的脉冲神经元：具有硬重置的 LIF（LIF-HR）；具有软重置的 LIF（LIF-SR）；具有硬重置的 IF（IF-HR）；具有软重置的 IF（IF-SR）。


一个常被忽视的事实是，放电机制（式（2））也会影响整合和重置机制。因此，二进制脉冲放电至少给脉冲神经元引入了两个内在缺陷：

i) 空间表征。我们无法评估当前空间输入的重要性。无论膜电位有多大，输出都只是一个脉冲。这也可以解释为膜电位转换为脉冲过程中存在较大的量化误差。

ii) 时间动态性。不可能进行数据相关的记忆或遗忘。如公式（3）所示， $S[t]$ 只能取值 0 或 1，这意味着软重置只能遗忘固定值。

让我们以图 2 中的脉冲神经元为例。

假设第 $(t-1)$ 时刻的空间输入非常重要（数值很大）。在硬重置的情况下，脉冲神经元会输出一个脉冲，并将膜电位清除至 V 。显然，这存在较大的量化误差，无法反映输入非常重要的事实。在软重置的情况下，脉冲神经元会输出一个脉冲，但传递到下一个时间步的膜电位仍然很大。一种可能性是，脉冲神经元随后会持续放电很长时间，这样就无法判断第 t 时刻的放电是由第 $(t-1)$ 时刻的空间输入引起的，还是由其他因素引起的。



一种可能性是，脉冲神经元在重置机制失效后会持续放电很长时间（图 2：重置机制对脉冲神经元时空动态的影响）。a) 第 (t-1) 步和第 (t+2) 步的输入大于阈值，而第 t 步和第 (t+1) 步的输入不大于阈值。这里我们设定 $\beta=1$ 。b) 如果没有重置，脉冲神经元会在输入超过阈值后持续放电。c) 如果硬重置为零，则当前时间步的空间输入只要超过阈值就会触发脉冲。未超过阈值的输入不会触发脉冲。d) 如果是软重置，则第 t 步的膜电位包含第 (t-1) 步的部分信息；即使第 t 步的输入很小，也可能触发脉冲。




图 3：脉冲发放模式。假设近似值为 0.3 ($a=0.3$)，即需要在十个时间步长 ($D=10$) 内发放三个脉冲。对于 ANN2SNN 和直接训练 SNN，这三个脉冲出现的时间步长是同步且随机的，其中同步意味着必须完成所有十个时间步长才能计算脉冲发放率。相比之下，SFA 训练在前三个时间步长发放脉冲后，在剩余的七个时间步长内不会发放脉冲。因此，SFA 中的脉冲发放可以异步实现（详见 6.1 节）。

我们假设脉冲神经元在空间维度上传递脉冲发放率（连续值）。在步骤 1 中，脉冲神经元的脉冲发放率 a 定义为发放的脉冲数与总时间步长的比值：

$$a = \frac{1}{D} \sum_{d=1}^D S[d], \quad (4)$$

其中 $\{S[d]\}$ 是 ANN2SNN 中的脉冲序列，或在第 l 层经过给定 D 个时间步的直接训练。

在步骤 2 中，我们执行整数激活训练，即使用整数来近似 a 。我们使用 $d=1$ $S[d]$ 以单个时间步长的整数值激活：

$$S = \text{Fire}(U) = [\text{clip}(U, 0, D)], \quad (5)$$

其中， S 表示 $[0, D]$ 范围内的整数激活值， U 表示放电前的膜电位， $\text{Fire}(\cdot)$ 表示整数值的放电函数， D 表示允许放电的最大整数值。 $\text{clip}(U, 0, D)$ 将 U 的值限制在 0 到 D 之间， $[\cdot]$ 表示四舍五入到最近的整数。

当前空间输入（如图 2(d) 所示）。因此，软重置可能导致每个时间步的记忆和遗忘处理过程完全相同。

在步骤 3 中，我们进行脉冲激活推断：

$$S = \sum_{d=1}^D \hat{S}[d], \quad (6)$$


其中 $\{\hat{S}[d]\}$ 是我们 SFA 训练中的脉冲序列。第 $(l+1)$ 层脉冲神经元的空间输入为

$$X=W=W \quad \frac{1}{D} S = \left(\frac{1}{D} \text{在} \right) \sum_{d=1}^D \hat{S}[d].$$

(7) 简而言之，SFA 方法在训练过程中将公式 (2) 中的 $S[t]$ 替换为 S_d ；在推理过程中，每个时间步被扩展为 $1 \times D$ 个时间步，对应的脉冲序列为 $\{\hat{S}[d]\}$ 。SFA 的整数脉冲发放不仅降低了将脉冲神经元膜电位转换为脉冲时的量化误差，而且增强了脉冲神经元在当前时间步的遗忘能力，从而弥补了时间动态方面的不足。SFA 方法的更多细节将在第 4 节中给出。此外，在第 5 节中，我们将系统地分析用我们提出的 $\{\hat{S}[d]\}$ 脉冲发放模式替换现有的 $\{S[d]\}$ 的情况。

SFA 训练和推理。现有的 ANN2SNN[14]

而直接训练的 SNN [66]、[67]、[68] 可以理解为速率编码（图 3）。受此启发



在第 5 节图 4 中: E-SpikeFormer 概览。总体而言,我们在宏观层面上遵循 Meta-SpikeFormer [28] 的设计,例如基于 CNN 和基于 Transformer 的 SNN 模块及其在各阶段的比例。我们重新设计了基于 CNN 和 Transformer 的 SNN 模块的内部结构,以实现高效的架构。图中,我们用绿色或粉色标记了所有升级后的设计。在绿色部分,我们在基于 CNN 的模块的 DWConv 层之后插入了一个 BN 层和一个脉冲神经元层,以避免重新参数化后由于卷积核尺寸增大而导致的功耗增加。在粉色部分,我们将[28]中的重参数化卷积(RepConv)替换为线性层以降低功耗,并通过增加 V 的通道数来补偿潜在的性能损失。此外,我们还在[28]中基于 Transformer 的 SNN 模块中添加了脉冲可分离卷积(SpikeSepConv)模块,这有助于提升性能。

(图 3) 对 SNN 的训练、性能、能耗和扩展性有深远的影响。

3.3 E-SpikeFormer

Meta-SpikeFormer [28] 探索了脉冲驱动自注意力机制 (SDSA) 中脉冲神经网络 (SNN) 的元设计、架构和捷径。本文重点在于基于 Meta-SpikeFormer 设计一种更高效的 SNN,并将其命名为“E-SpikeFormer”。

概述。E-SpikeFormer 包含基于卷积和基于 Transformer 的 SNN 阶段 (图 4)。每个阶段包含多个模块,每个模块包含一个标记混合器模块和一个通道混合器模块。Meta-SpikeFormer 中使用了大量的重参数化卷积 (RepConv),导致功耗显著增加。根据 Meta-SpikeFormer 的表 5, RepConv 部分约占总能耗的 60%。本文中,我们消除了所有 RepConv,并通过引入一组额外的轻量级脉冲可分离卷积 (SpikeSepConv) 来补偿性能损失。在图 4 中,我们将 E-SpikeFormer 相对于 MetaSpikeFormer 的所有升级设计分别标记为绿色或粉色。我们可以看到,我们的方法主要有三个改进: i) 在基于卷积的 SNN 模块中,标记混合器已被 SpikeSepConv 取代; ii) 在标记混合器之前添加了一个 SpikeSepConv 模块 (即 SpikeSepConv)。

iii) 在基于 Transformer 的 SNN 模块中,SDSA 模块; iii) 在 SDSA 模块中, RepConv 被线性运算所取代。


[28] 中的基于卷积的 SNN 模块使用可分离卷积 [69] 作为标记混合器。然而,在 SNN 中,深度卷积和逐点卷积之间的直接连接以及后续的重参数化会带来严重的能耗问题。我们的解决方案是在深度卷积和逐点卷积之间添加一个批量归一化 (BN) 层 [70] 和一个脉冲神经元层。具体来说,我们基于 CNN 的 SNN 模块可以写成如下形式:

$$U = U + \text{SpikeSepConv}(U), \quad (8) \quad U = U + \text{ChannelConv}(U), \quad (9) \\ \text{SpikeSepConv}(U) = \text{Conv}$$

$$\text{SN 会议} \quad (10) \\ \text{SN 会议} \quad \text{SN}(U) \quad , \\ \text{ChannelConv}(U) = \text{Conv}(\text{SN}(\text{Conv}(\text{SN}(U)))) \quad (11)$$

其中, SpikeSepConv(·) 是标记混合器, ChannelConv(·) 是通道混合器, Conv(·) 和 Conv(·) 是逐点卷积, Conv(·) 是深度可分离卷积 [71], Conv(·) 是普通卷积。SN(·) 是脉冲神经元层。注意,为了简化表述,我们忽略了 BN 层。

基于 Transformer 的 SNN 模块。受以下因素的启发: 基于以下观察: 在自注意力算子之前添加卷积层以提取局部特征可以增强全局特征的融合 [72], [73], 我们引入了一种



[73] 图 5: E-SpikeFormer 中 MIM 预训练的概览。它由一个 SNN 编码器和一个 ANN 解码器组成。编码器仅处理可见像素。解码器重构图像以学习表征, 这些表征将在微调阶段被移除。使用 Vanilla Spike Convolution (VSC) 作为编码器会导致信息泄露, 因此我们设计了 Spike Sparse Convolution (SSC) 来避免这一缺陷。图中白色和黑色分别代表 1 和 0 区域。使用 VSC 会导致黑色 0 区域随着深度的增加而不断扩大, 直到没有有效信息为止。我们证明, 由于 SNN 的脉冲驱动特性, SSC 非常适合神经形态芯片 (第 6.2 节)。

在 SDSA 之前添加一个轻量级的 SSC 模块。此添加旨在抵消因移除 RepConv 而导致的性能下降。然后, 基于 Transformer 的 SNN 模块可以写成如下形式:

$$U = U + \text{SpikeSepConv}(U), U = U + \text{E-SDSA}(U), U = U + \text{ChannelMLP}(U),$$

其中 E-SDSA($\cdot$) 是所提出的 E-SDSA 模块。

高效脉冲驱动自注意力机制 (E-SDSA) Mod- 本文将 K、Q、V 的生成、SDSA 算子以及后续的线性算子组合成 E-SDSA 模块 (图 4 中的粉色模块)。在 E-SDSA 中, 我们利用线性运算生成 K、Q 和 V, 而不是耗能的重参数化卷积。我们采用了文献 [74] 中的 iRMB 技术, 该技术将 V 的通道数扩展 γ 倍, 以增强 E-SDSA 的表示能力。具体而言, E-SDSA 模块可以写成如下形式:

$$Q = \text{SN}(\text{Linear}(U)), K = \text{SN}(\text{Linear}(U)), V = \text{SN}(\text{Linear}(U)), U = \text{Linear}(\text{SN}(QKV * \text{scale})),$$

其中 $\text{Linear}(\cdot)$ 是一个线性算子, 其可学习矩阵为 $W \in \mathbb{R}$ 和 bias $b \in \mathbb{R}$ (C 分别为输入和输出的维度)。其数学形式可以写成 $y = Wx + b$ 。类似地, $\text{Linear}(\cdot)$ 的权重为 $W \in \mathbb{R}$ 和 bias $b \in \mathbb{R}$ 。类似地, $\text{Linear}(\cdot)$ 的权重为 $W \in \mathbb{R}$ 和 bias $b \in \mathbb{R}$ 。

$b \in \mathbb{R}$ 。SN($QKV * \text{scale}$) 是 SDSA 算子, 与 Meta-SpikeFormer [28] 一致, 常数尺度因子可以重新参数化为 SN 的阈值。

3.4 用于扩展 SNN 的脉冲稀疏卷积

直接缩放 ViT 会导致性能下降 [47]、[75]。本文提出的 E-SpikeFormer 也未能避免这个问题。预训练-微调 MIM 范式是解决性能下降问题的常用方法之一 [30]。Tian 等人 [31] 指出, MIM 策略不能直接应用于 CNN。在 ViT 中, 输入图像被分割成互不重叠的图像块。得益于 ViT 处理不规则且互不重叠图像块的能力, MIM 可以直接丢弃被掩码的图像块来移除信息。相比之下, CNN 不仅在规则网格上进行操作, 而且还执行带有重叠的滑动窗口操作。直接在 CNN 中使用 MIM 会导致信息泄露。也就是说, 由于输入包含大量空白 (掩码) 区域, 随着网络深度的增加, 深度卷积几乎无法学习到任何特征。Tian 等人提出了一种名为 SparK [31] 的解决方案, 该方案涉及在应用零掩码后, 使用稀疏卷积编码器对输入图像进行编码。

所提出的 MIM-SNN 遵循 SparK (图 5), 但采用了新设计的尖峰稀疏卷积 (SSC) 编码器。整个过程可以表示为 $G = F \circ F$, 体现了编码器-解码器架构。编码器 F 负责将掩码输入 X 映射到潜在特征 $Z = F(X)$ 。解码器 F 则反向执行此过程, 将 Z 映射回像素空间以重建目标视图 X (X 和 X 互为互补)。

掩膜。逐块掩膜是 MIM 的第一步。

图像 X 被重构为一系列扁平化的二维图像块, $X \in \mathbb{R}$, 其中 p 表示图像块的大小。然后生成一个随机二值掩码 $m \in \{0, 1\}$, 从而能够获取 X 的两个互补的掩码视图 [76]:

$$X = X[n] \in \mathbb{R}, X = X[1 - n] \in \mathbb{R}, \quad (12)$$

随机生成稀有整数, 使得 $r = n(1 - \mu)$ 且 $r = n\mu$, 保证它们的和等于 n , μ 为掩码率。

编码器。掩码图像类似于神经形态数据，仅在亮度变化时才有事件发生，因此包含大片空白（零）区域。直观地说，由于脉冲神经网络（SNN）的脉冲驱动特性，其中的卷积自然是稀疏卷积。如图 5 所示，根据输入脉冲的地址，地址映射函数 [10] 输出需要执行稀疏突触加法操作的神经元和突触的地址。然而，使用普通脉冲卷积（VSC）无法避免 MIM-SNN 中的信息泄漏。这种差异源于 VSC 会在所有位置执行卷积，最终导致信息泄漏（也可以称为脉冲退化 [45]，即深层脉冲神经元几乎不再产生脉冲）。

为了应对这一挑战，我们提出了 SSC 算法，它仅对未被掩码的位置进行卷积。我们在 d 维空间中将 X 重塑为具有 C 个通道、高度为 H 、宽度为 W 的特征。我们使用 SSC 算法处理该特征，其中 $W \in R$ 为卷积核权重。例如，在二维坐标空间中， W 包含 $C \times C$ 个通道，卷积核大小为 K ，且 $K=3$ 。SSC 的卷积过程表示如下：

$$Y = \sum_{k \in K} \alpha(W \cdot X), \quad (13)$$

其中 k 枚举核空间 K 中的所有离散位置。 $p = p + k$ 是中心 p 周围的对应位置，其中 k 是到 p 的偏移距离。 $\alpha \in \{0, 1\}$ 是一个选择器。当中心 $p \in X_i$ 时，如果该区域被掩蔽，则 α 为 0，表示点 p 不参与计算，从而保留掩蔽的特征图。 $\alpha = 1$ 表示该区域未被掩蔽，可以参与计算。在预训练期间，编码器采用 SSC；在微调期间，权重转换回 VSC。

解码器。编码器的输出连同可学习的掩码标记一起提供给解码器。然后，掩码标记被重构为图像。解码器通常有两种选择：普通 [57] 和多尺度 [31] 人工神经网络。我们发现不同的解码器对 MIM-SNN 预训练的准确率影响较小。因此，在预训练期间，我们采用了普通人工神经网络（Transformer）作为解码器，该解码器在微调阶段被移除，不会影响 SNN 的脉冲驱动推理。

损失函数。在预训练中，我们使用均方误差损失作为度量函数 L ，并将每个掩码块的归一化像素值作为预测目标。

$$L = EE \| F(F(X)) - X \|, \quad (14)$$

其中 $F(F(X))$ 是解码器输出， $\| \cdot \|$ 是 l 范数。

然后我们在微调过程中利用蒸馏 [75] 技术，这与 Meta-SpikeFormer [28] 中的技术相同。

对 MIM-SNN 的分析。在第 5.4 节中，我们揭示了二进制脉冲如何影响 SNN 的缩放。在第 6.2 节中，我们表明 SSC 和我们的 VSC 之间的区别在于地址映射函数 [10]，因此神经形态芯片天然能够执行基于 SSC 的 MIM-SNN 预训练。

4. 脉冲发放近似分析

首先，我们证明了基于整数的训练与 SFA 方法中相应的脉冲序列推断是等价的。随后，我们分析了用整数激活值代替脉冲发放率所产生的近似误差。

4.1 脉冲驱动推理的实现

通过 $V=1$ 的 IF-SR 神经元，可以无损地实现整数训练和脉冲推理之间的过渡。

命题 1. 考虑 SNN 中第 l 层的 $\text{Fire}(\cdot)$ 函数，其整数输出等于 D 个时间步长的 IF-SR 脉冲神经元产生的脉冲之和：

$$S = \sum_{d=1}^D \hat{S}[d], \quad (15)$$

其中 S_i 是第 l 层 $\text{Fire}(\cdot)$ 触发的整数值， $\{\hat{S}[d]\}$ 是给定 D 个时间步长内， $V=1$ 的 IF-SR 脉冲神经元生成的脉冲序列。

证明。将公式 (5) 的膜电位输入送入 $V=1$ 的 IF-SR 神经元，生成的脉冲序列为：

$$\{\hat{S}[d]\} = \text{IF-SR}(U), \quad (16)$$

这意味着 IF-SR 脉冲神经元在每个时间步长都减去 1，直到膜电位低于阈值。其基本假设是，仅在时间步长 $d=1$ 时输入非零，而在时间步长 $d=2, \dots, D$ 时输入为零。那么脉冲序列的总和为：

$$\sum_{d=1}^D \hat{S}[d] = \lfloor \text{clip}\{U, 0, D\} \rfloor, \quad (17)$$

其中 $\lfloor \cdot \rfloor$ 表示向下取整函数。根据式 (5)，我们有：

$$S = \lfloor \text{clip}\{U, 0, D\} \rfloor, \quad (18) = \lfloor \text{clip}\{U + 0.5, 0, D\} \rfloor, \quad (19) = \lfloor \text{clip}\{U, 0, D\} \rfloor, \quad (20)$$

其中，在式 (20) 中，关于四舍五入函数 $\lfloor \cdot \rfloor$ 和向下取整函数 $\lfloor \cdot \rfloor$ 之间等价性的偏差“0.5”可以纳入权重中。结合式 (17) 和式 (20)，我们得到：

$$S = \lfloor \text{clip}\{U, 0, D\} \rfloor = \sum_{d=1}^D \hat{S}[d]. \quad (21)$$

□

公式 (21) 表明整数训练等价于脉冲序列推理。我们将分析这如何根据任务类型影响训练。

针对静态视觉任务的单步 SFA 训练。静态视觉任务，例如分类和检测，不包含时间信息。如图 6(a) 所示，为了克服脉冲神经元在空间表征方面的缺陷，以往的直接训练通过重复输入强制构建多时间步速率编码。由于 SFA 训练改变了脉冲发放模式，对于静态任务，我们只需要进行单时间步训练，然后将其转换为多时间步脉冲驱动推理（图 6(b)）。SFA 训练具有以下特点：




图 6(b): SNN 中标准训练和 SFA 训练的比较。SNN 中的 T 通常表示时间步长。对于标准训练的 SNN, T 在训练和推理阶段保持一致。在 SFA 训练中, 训练阶段的时间步长为 T , 但在推理阶段会扩展到 $T \times D$ 个时间步长 (图中的神经元为 IF-SR)。由于 SFA 训练中的激活值是整数, 因此 D 的另一个含义是训练期间允许的激活值整数上限。在标准训练的 SNN 中, D 等于 1。(a) 直接训练对静态和动态视觉任务使用相同的处理方法。由于 $D=1$, 直接训练无法避免动态视觉任务中二进制脉冲发放的机制缺陷。(b) 对于静态任务, SFA 方法在训练成本 (单步训练) 和推理能量成本 (图像仅输入一次) 方面具有优势。(c) 对于动态任务, SFA 方法可以通过扩大时间步长同时减轻脉冲神经元在空间表征和时间动态方面的缺陷。

与传统训练相比, 有两个明显的优势: 第一, 单步训练成本更低; 第二, 在推理过程中, SFA 不需要重复输入图像。

用于动态视觉的多时间步 SFA 训练

对于时间动态视觉任务, 多时间步模拟不能被理解为速率编码, 但在直接训练中仍然采用与静态任务相同的处理方法。因此, 在动态视觉任务中, 二进制脉冲发放的空间表征和时间动态缺陷会在直接训练中同时显现。

SFA 训练通过在推理过程中将时间步长扩展到 $T \times D$ 来克服这两个缺陷: 首先, 整数值反映了空间输入的重要性; 其次, 整数的大小由空间输入决定, 因此是一种数据相关的机制, 相当于脉冲神经元可以动态遗忘 (软重置)。总之, SFA 训练中的每个时间步长都被扩展到 $1 \times D$ 个时间步长。

这可以看作是同时执行两种重置机制。当时间步长在 $[(t-1) \times D + 1, t \times D]$ 范围内时, 使用 IF-SR 神经元。当时间步长在 $[1, \dots, (t-1) \times D, t \times D, \dots, T \times D]$ 范围内时, 可以应用 LIF-HR/LIF-SR/IF-HR/IF-SR 动态机制。我们将在 6.1 节讨论如何在神经形态芯片中实现这种混合脉冲神经元机制。

4.2 近似误差分析

使用有限整数值来近似连续脉冲发放率会引入近似误差。第 l 层在 D 个时间步内的脉冲发放率为:

$$a = \frac{1}{D} S = \frac{1}{D} \text{火灾}(U) = \frac{1}{D} [\text{clip}\{U, 0, D\}]. \quad (22)$$

定义 1 (前向近似误差)。给定 l 层连续输入膜电位 $U[d]$, 我们定义近似误差如下:

$$\text{Err} = \text{ReLU}(U[d]) - F(U[d]), \quad (23)$$

其中 $\text{ReLU}(\cdot)$ 表示 ReLU 函数, $F(\cdot)$ 是近似函数。在理想情况下, 当 $F(U[d]) = \text{ReLU}(U[d])$ 时, 近似误差等于零。

由于 SFA 中的近似函数为 $F(\cdot) =$
根据定义 1, $\text{D Fire}(\cdot)$ 的近似误差为:

$$\text{Err} = \text{ReLU}(U[d]) - \frac{1}{D} [\text{clip}\{U[d], 0, D\}]. \quad (24)$$

继续进行以下扣除:

$$\begin{aligned} & \begin{cases} \text{错误} = \begin{cases} \text{若 } 0 \leq U[d] < D, \text{ 则 } U[d] - [U[d]] \\ U[d] - 1, \text{ 如果 } U[d] \geq D \end{cases} \end{cases} \quad (25) \\ & \begin{cases} \text{错误} = \begin{cases} \text{若 } 0 \leq U[d] < D, \text{ 则 } U[d] - [U[d]] \\ U[d] - 1, \text{ 如果 } U[d] \geq D \end{cases} \end{cases} \end{aligned}$$

在反向传播阶段, SFA (公式 (5)) 不可微。以往的研究引入了各种替代梯度函数 [16]、[25], 主要用于处理二进制脉冲输出。在我们的方法中, 我们始终使用矩形窗作为替代函数。为简单起见, 我们仅保留在 $[0, D]$ 范围内激活的神经元的梯度, 并将其他神经元的梯度设为零。

使用矩形窗作为代理函数无法避免梯度误差。我们将此梯度误差定义为代理梯度函数的积分与 SFA 前向逼近函数的积分之差, 可以表示如下:

定义 2 (反向梯度误差)。给定 l 层连续输入膜电位 $U[d]$, 我们定义梯度误差如下:

$$\text{错误} = \int_{-\infty}^Z \text{Rect}(U[d]) - F(U[d]), \quad (26)$$

其中 $\text{Rect}(\cdot)$ 是介于 0 和 D 之间的矩形窗口。 $F(\cdot)$ 是近似函数。在理想情况下, $\nabla F(U[d]) = \text{Rect}(U[d])$, 梯度误差等于零。

根据定义 2, 梯度误差为:

$$\text{错误} = \int_{-\infty}^Z \text{Rect}(U[d]) - \frac{1}{D} [\text{clip}\{U[d], 0, D\}]. \quad (27)$$

继续进行以下扣除:

$$\begin{aligned} & \begin{cases} \text{错误} = \begin{cases} \text{若 } 0 \leq U[d] < D, \text{ 则 } U[d] - [U[d]] \\ 1, \text{ 如果 } U[d] \geq D \end{cases} \end{cases} \quad (28) \\ & \begin{cases} \text{错误} = \begin{cases} \text{若 } 0 \leq U[d] < D, \text{ 则 } U[d] - [U[d]] \\ 1, \text{ 如果 } U[d] \geq D \end{cases} \end{cases} \end{aligned}$$

在本小节中, 我们将考察 SFA 中 $\text{Fire}(\cdot)$ 函数引入的近似误差和梯度误差, 如公式 (25) 和 (28) 所示。我们的分析表明, 时间步长 D 越大, 误差越小。需要注意的是, 较大的时间步长可能会增加延迟和能耗。

5 项实验

在第 5.1 节中, 我们报告了所提出方法在各种视觉任务上的主要结果。在第 5.2 节中, 我们对 SFA、E-SpikeFormer 和 MIM 预训练进行了消融实验。第 5.3 节和第 5.4 节分析了 SFA 对 SNN 的性能、功耗和可扩展性的影响。




图 7: 在 8 块 NVIDIA-A100-40G 显卡上, 使用 Vanilla 和 SFA 算法在 ImageNet 数据集上进行 200 个 epoch 训练的耗时。在静态数据集上, 训练阶段使用 $T = 1$, 推理阶段则扩展到 D 个时间步。由于我们仅利用了一个时间步进行训练, 因此训练成本显著降低。

5.1 主要结果

我们在多种任务上评估了我们的方法, 包括图像分类 (ImageNet-1k [32])、目标检测 (COCO [33])、语义分割 (ADE20K [34]) 和神经形态任务 (HAR-DVS [35]、CIFAR10-DVS [93])。我们遵循 [28] 中的预训练和微调方法, 在 COCO 和 ADE20K 数据集上测试 ESpikeFormer。在 ImageNet 上训练的模型用于微调检测或分割头。性能评估方法和训练/配置的详细信息分别在补充材料的 S1 节和 S2 节中给出。

5.1.1 图像分类

所提出的方法在 ImageNet-1K [32] 上以 6 个模型规模 (表 1) 进行了验证, ImageNet-1K 是一个著名的数据集, 包含 130 万张训练图像和 5 万张验证图像, 涵盖 1000 个类别。

与之前的 SNN 基线相比, 我们理解-

我们将 E-SpikeFormer 与之前的 SNN 在准确率、参数量和功耗方面进行了全面比较。E-SpikeFormer 达到了目前最先进的水平, 并展现出明显的综合优势, 例如, E-SpikeFormer 与 Meta-SpikeFormer [28] 和 MS-ResNet [45] 相比: 参数量分别为 1900 万、5500 万和 7700 万; 准确率分别为 79.8%、80.0% 和 76.3%; 功耗分别为 5.9 mJ、52.4 mJ 和 10.2 mJ。我们显著提升了 SNN 在 ImageNet 上的准确率。在 500 万、1000 万和 1900 万的小规模模型中, 我们分别达到了 75.3%、78.5% 和 79.8% 的准确率, 远超之前的 SNN。我们将 SNN 的规模和性能上限分别提升至 1.73 亿和 86.2%。针对性高效的架构设计显著降低了模型的功耗。我们在 5.2 节中给出了相关的消融实验结果。SFA 设置中的 D 值会影响准确率和功耗 (5.3 节) 以及模型规模 (5.4 节)。由于我们在 ImageNet 数据集上采用单步训练, 训练成本也显著降低。如图 7 所示, 我们在各种规模下都获得了约 9 倍的训练加速, 并且从 1×4 到 1×8 的规模变化并未导致训练时间的增加。此外, 我们在 S3 节中提供了 SFA 方法的 GPU 内存加速比。

与 ANN 基线相比, E- 的准确率 SpikeFormer 在保持能效优势的同时, 性能已经超越或媲美某些经典的 ANN。例如, 在 8000 万规模下, E-SpikeFormer

在 8000 万图像规模下，表 1：与 ImageNet-1k 上先前工作的比较。默认推理输入分辨率为 224×224 。* 推理时，输入裁剪区域放大至 384×384 。我们将所有直接训练 SNN 的时间步长重写为 $T \times D$ 的格式，其中 T 表示时间步长，D 表示训练期间整数激活值的上限。在之前的 SNN 中，D 的默认值为 1。注意，本文所有表头中的“Param”和“Step”分别表示“参数”和“时间步长”，并且所有直接训练 SNN 中涉及的“Step”默认都以 $T \times D$ 的形式表示。

方法	建筑学	尖峰驱动参数 (M)	功率 (mJ)	步进 Top-1 准确率 (%)			
ANN	DeiT-S [75] $\times$ 22.0 21.2 1 79.8 PVT-S [77] $\times$ 24.5 35.0 1 79.8 Swin-T [78] $\times$ 29.0 20.7 1 81.3 CAFormer-M36 [79] $\times$ 60.65. 85.2 T2T-ViT-24 [80] $\times$ 64.1 69.0 1 82.6 RepLNet-31B [81] $\times$ 79.0 70.4 1 83.5 DeiT-B [75] $\times$ 86.0 80.5 焦点 (FLRNet-1818)。 [82] $\times$ 88.7 70.8 1 83.9 ConvNeXt-B [83] $\times$ 89.0 70.8 1 83.8						
	Focal-B [84] $\times$ 89.8 73.6 1 83.8 CrossFormer-L [85] $\times$ 92.0 74.1 1 84.0						
	ResNet-34 [12] $\checkmark$ 21.8 - 250 61.5 最优 ANN2SNN [86] $\checkmark$ -- 1024 74.3 串联 VGG-16 [14]						
ANN2SNN	快速 SNN [87]	$\checkmark$	-	- 16	73.0		
		$\checkmark$	138.4	- 7	73.0		
掩码脉冲变换器 [15] $\times$ 28.5 - 512 78.5 两阶段 ANN2SNN [88] $\checkmark$ -- 128 74.9							
SEW-ResNet [18] $\times$ 60.2 12.9 4 $\times$ 1 69.2 TET-ResNet [89] $\times$ 21.8 - 4 $\times$ 1 68.0 DSR-ResNet [90] $\times$ 11.2 - 50 $\times$ 1 67.7 GAC-MS-ResNet [91] $\checkmark$ 21.93 2.2 4 $\times$ 1 69.7 MS-ResNet [45] $\checkmark$ 77.3 10.2 4 $\times$ 1 75.3 Att-MS-ResNet [21] $\times$ 78.4 7.3 4 $\times$ 1 77.1 * Spikformer [50] $\times$ 66.3 21.5 4 $\times$ 1 74.8 Spike-driven Transformer [29] $\checkmark$ 66.3 6.1 4 $\times$ 1 76.3							
直接的训练							
	Spikformer v2 [92]	$\times$	172.7 25.6 4 $\times$ 1 82.4				
	Meta-SpikeFormer [28]	$\checkmark$	15.1 16.7 4 $\times$ 1 74.1				
		$\checkmark$	31.3 32.8 4 $\times$ 1 77.2				
		$\checkmark$	55.4 52.4 4 $\times$ 1 80.0				
		$\checkmark$	5.1 1.7 1 $\times$ 4 75.3				
		$\checkmark$	10.0 3.0 1 $\times$ 4 78.5				
		$\checkmark$	19.0 5.9 1 $\times$ 4 79.8				
		$\checkmark$	52.0 14.4 1 $\times$ 4 80.6				
直接的训练	电尖峰形成器 (这项工作)	$\checkmark$	83.0 19.1 1 $\times$ 4 83.2				
		$\checkmark$	83.0 30.9 1 $\times$ 8 84.0				
		$\checkmark$	83.0 1 $\times$ 8 85.2 *				
		$\checkmark$	173.0 35.6 1 $\times$ 4 84.7				
		$\checkmark$	173.0 54.7 1 $\times$ 8 85.1				
		$\checkmark$	173.0	- 1 $\times$ 8	86.2 *		

与 ConvNeXt-B [83] 和 CrossFormer-L [85] 相比：参数量分别为 8300 万、8900 万和 9200 万；准确率分别为 83.2%、83.8% 和 84.0%；功耗分别为 19.1 mJ、70.8 mJ 和 74.1 mJ。在 2000 万规模下，E-SpikeFormer 与 DeiT-S [75] 和 PVT-S [77] 相比：参数量分别为 1900 万、2200 万和 2450 万；准确率分别为 79.8%、79.8% 和 79.8%；功耗分别为 5.9 mJ、21.2 mJ 和 35.0 mJ。这是 SNN 领域首次能够与经典 ANN-ViT 模型的性能相媲美。

5.1.2 目标检测

在 Meta-SpikeFormer [28] 出现之前，SNN 领域只能通过特定的架构设计来处理目标检测任务，且准确率较低。Meta-SpikeFormer 使 SNN 能够以统一的方式处理目标检测和语义分割等密集预测任务。本文在 COCO 数据集 [33] 上测试了 E-SpikeFormer，该数据集包含 118K 张训练图像 (train2017) 和 5K 张验证图像 (val2017)。结果如表 2 所示，E-SpikeFormer 在 SNN 领域取得了最先进的性能，并且在 ANN 领域超越或与经典模型相当，但能耗更低。例如

ESpikeFormer vs. Meta-SpikeFormer [28] vs. PVT-Tiny [77]: Param, 38.7M vs. 75.0M vs. 32.9M; mAP@0.5, 对比 58.8% 51.2% 对 56.7%; 功率, 119.5mJ 对 140.8mJ 对 1040.5mJ。

5.1.3 语义分割

ADE20K [34] 是一个具有挑战性的语义分割基准数据集，其训练集和验证集分别包含 2 万张和 2 千张图像，涵盖 150 个类别。Meta-SpikeFormer [28] 首次报道了 SNN 在 ADE20K 数据集上的结果。我们沿用 Meta-SpikeFormer 的实验设置，在 ADE20K 上测试了我们的 E-SpikeFormer 模型。我们的模型在 ADE20K 上表现良好。例如，E-SpikeFormer 与 Meta-SpikeFormer [28] 的对比：参数，1100 万 vs. 2000 万。

59.8M; mIoU, 41.4% 对 35.3%; 功率, 33.6mJ 对 183.6mJ。

5.1.4 拟人化人体动作识别

HAR-DVS [35] 是目前最大的基于事件的人体活动识别 (HAR) 数据集，包含 300 个类别和 107,646 个样本，由 DAVIS346 相机采集，空间分辨率为 346×260 。我们使用 HAR-DVS 来评估 E-SpikeFormer、数据预处理和实验方法。

我们使用 HAR-DVS 来评估 E-SpikeFormer，表 2: COCO val2017 上的检测性能 [33]。* 这些方法利用 ImageNet 上的预训练模型作为骨干网络，然后添加检测头进行微调。

方法架构	帕拉姆 (M)	力量 (毫焦耳)	步骤	地图 @50(%)
ANN	ResNet-18 [51] 31.2	890.6	154.0	PVT-Tiny [77] 32.9
	1040.5	156.7	DETR-DC5 [94] 41.0	860.2
			155.7	
ANN2SNN	Spiking-YOLO [95] 10.2	3500	25.7	脉冲校准 [96] 17.1
	512	45.3	快速 SNN [13] 25.1	15 46.4
直接的训练	Spiking Retina [97] 11.3	4 × 128.5	EMS-Res-SNN [98] 26.9	4 × 150.1
	Meta-SpikeFormer * [28]	34.9	49.5	1 × 144.0
		75.0	140.8	1 × 151.2
直接的训练	E-SpikeFormer * (这项工作)	38.7	56.2	1 × 241.8
		38.7	94.5	1 × 458.4
		38.7	119.5	1 × 858.8

表 3: ADE20K 数据集上的分割性能 [34]。* 这些方法使用 ImageNet 上预训练的模型作为骨干网络，然后添加分割头进行微调。

方法架构	帕拉姆 (M)	力量 (毫焦耳)	步骤	MIoU (%)
ANN	ResNet-18 [51] 15.5	147.1	132.9	PVT-Tiny [77] 17.0
	35.7	PVT-Small [77] 28.2	204.7	139.8
	59.0	217.1	214.8	ConvNeXt-T [83] 60.0
	217.3	145.8	DeepLab-V3 [100] 68.1	1240.6
		142.7		
直接的训练	元 SpikeFormer * [28]	16.5	22.1	1 × 132.3
		16.5	88.1	4 × 133.6
		59.8	46.6	1 × 134.8
		59.8	183.6	4 × 135.3
直接的训练	E-SpikeFormer * (这项工作)	11.0	18.4	1 × 231.9
		11.0	27.2	1 × 440.1
		11.0	33.6	1 × 841.4

设计（请参见 S2.2 节）沿用了之前的 MetaSpikeFormer。我们采用直接训练的方式处理 HAR-DVS 数据集，训练参数 T=8。Meta-SpikeFormer 的精度与人工神经网络（ANN）相当，并且优于之前的脉冲神经网络（SNN）（表 4）。我们还在神经形态 CIFAR10-DVS 数据集上验证了我们方法的有效性，实验结果见补充材料（S4 节）。

5.2 消融研究

在表 5 中，我们进行了严格的消融实验，以验证 SFA 训练和 E-SpikeFormer 与基线（Meta-SpikeFormer [28]）在 ImageNet 上的增益。

i) 基线+基线+SFA: 步长, 4×1 vs. 1×4 ; 功率, 11.9mJ vs. 7.3mJ (-4.6mJ); 准确率, 71.3% vs. 77.8% (+6.5%)。这表明, SFA 策略比直接训练 SNN 更有效率。

ii) 我们改进了 SNN 架构, Baseline+SFA 与 E-SpikeFormer+SFA: 功耗分别为 7.3mJ 和 3.7mJ (降低 4.3mJ); 准确率分别为 77.8% 和 78.5% (提高 0.7%)。所提出的高效架构设计在降低功耗的同时, 进一步提高了准确率。

此外, 我们观察了 SFA 方法对能源成本的影响, 并在 5.3 节进行了深入分析。总之, 通过结合 SFA 和 E-SpikeFormer

与表 4 相比: 神经形态人类动作识别在 HAR-DVS 上的性能 [35]。

方法架构	帕拉姆 (M)	力量 (毫焦耳)	步骤	准确率(%)
ANN	SlowFast [101] 33.6	8×146.5	ACTION-Net [102] 27.9	8×146.9
	TimeSformer [103] 121.2	8×150.8		
直接的训练	Res-SNN-34 [18] 21.8	8×146.1	ASA-SNN [104] 41.5	8×147.1
	Meta-SpikeFormer [28] 18.3	8.0×147.5		
直接的训练	E-SpikeFormer (本作品)	18.7	18.1	8×448.9
		18.7	23.5	8×49.2

表 5: SFA 的消融研究和架构设计。

方法参数 (M)	步长功率 (mJ)	准确率 (%)
基线[28]	10.0	1×13.3
	10.0	4×11.9
+ 我们的 SFA 培训	10.0	1×47.3
+ 我们的架构	10.0	1×43.0
	78.5	(+0.7)

与 10M 基线 [28] 相比, 我们同时实现了 7.2% 的性能提升、5.3 倍的训练时间加速（在 8 个 NVIDIA-A100-40G 上, 200 个 epoch 的训练时间为 12 小时, 而 63 小时为 63 小时）以及 3.7 倍的推理能效提升。

由于篇幅限制, 关于 MIM 训练的消融实验放在补充材料的 S5 节中, 包括 MIM 掩模比例、解码器宽度和深度, 以及关于 MIM 和蒸馏的研究。

5.3 SFA 在功率和性能方面的优势

与 ANN2SNN 和直接训练相比, SFA 方法提出了一种新的脉冲发放模式（图 3）。我们在此重点关注以下问题: SFA 方法如何优化 SNN 的功率和性能?”

我们主要研究不同脉冲发放模式下的脉冲分布。首先, 我们定义网络脉冲发放率 (NSFR): 在时间步 t , SNN 的 NSFR 是该时间步所有神经元产生的脉冲数与神经元总数的比值。NSFR 用于评估同一网络在不同时间步的脉冲分布变化。默认情况下, 我们统计测试集中样本的脉冲发放率, 并取其平均值作为最终数据。其次, 我们在图 8 中可视化了 10M 模型最后一个模块最后一层脉冲分布图。特定 SNN 层的输出脉冲分布图以 4D ([T, C, H, W]) 的形式呈现, 可以沿通道维度进行平均, 得到 3D 分布图 ([T, H, W])。由于 $T = 4$, 我们可以将 3D 地图分割成四个 2D 地图, 即图 8 中间四个地图。每个脉冲地图的像素代表一个脉冲神经元的放电率。像素越红, 脉冲放电率越高; 像素越蓝, 脉冲放电率越接近于零。由此我们可以得出以下观察结果:

i) 功率优化。图 9 显示了使用标准方法和 SFA 方法训练的 SNN 的 NSFR。在标准训练中, 每个时间步的 NSFR 值都比较接近（蓝线）。相比之下, 使用 SFA 方法训练的 SNN 的 NSFR 值会随着时间步的增加而降低（橙线）。图 8 显示了使用标准方法获得的两个样本的脉冲分布。




图 8: ImageNet 数据集上原始训练和 SFA 训练的脉冲分布可视化。从上到下依次为: 原始训练和 SFA 训练。对于单个样本, 特定 SNN 层的输出脉冲图以 4D ($[T, C, H, W]$) 的形式呈现。我们首先将 4D 脉冲图沿通道维度平均, 得到 3D 图 ($[T, H, W]$)。由于 $T=4$, 我们可以将 3D 图分割成四个 2D 图 (图中中间四个图)。然后, 我们将 4D 脉冲图沿时间和通道维度平均, 得到 2D 图 ($[H, W]$), 从而得到最右侧的两个脉冲图。对于单个图, 每个像素代表一个脉冲神经元的放电率。像素颜色越红, 脉冲放电率越高。像素颜色越蓝, 脉冲发放率越接近于 0。中间四个脉冲图展示了原始训练和 SFA 训练所得脉冲分布在时间维度上的差异: 原始训练中脉冲发放率从左到右变化不大 (第一行); SFA 训练中脉冲发放率从左到右逐渐降低 (第二行)。最右侧的两个脉冲图表明, SFA 训练所得的脉冲特征更加清晰, 且发放率更低。

以及 SFA 训练。可以看出, SFA 训练得到的脉冲图 (每个样本的第二行) 颜色从左到右由红色变为蓝色, 这意味着随着时间步长的增加, 脉冲发放率降低。相比之下, 传统训练得到的脉冲图 (每个样本的第一行) 颜色变化不大。这一现象与图 9 中的数据相符。此外, SFA 训练和传统训练得到的脉冲神经元最高发放率 (图中红色像素的值) 分别为 0.19 和 0.78。

ii) 性能优化。如图 8 所示, 4D 脉冲图也可以在时间和通道维度上平均成 2D 图 ($[H, W]$), 从而得到最右侧的两个脉冲图。可以看出, 与原始训练相比, SFA 训练得到的脉冲特征更清晰, 且放电率更低。

5.4 二元脉冲发放机制不利于脉冲神经网络的扩展

我们在 3.4 节中从编码器设计的角度分析了直接缩放 E-SpikeFormer 导致性能下降的原因。问题在于, 在 MIM 的掩码操作叠加后, 原始脉冲卷积会泄露信息。我们提出了脉冲稀疏卷积来解决这个问题。此外, 我们观察到二进制脉冲发放也会干扰 SNN 的缩放。如图 10(a)所示, 我们从两个正交的角度分析了 SNN 的缩放: 有无 MIM-SNN 预训练以及 SFA 与直接训练。如图橙色线所示, 当使用 SFA 方法训练时, MIM 策略可以有效地帮助 SNN 进行缩放。然而, 在二进制脉冲的原始训练中, 即使使用 MIM 策略, 性能仍然会下降 (红色线)。

我们认为, 潜在的原因是二元性




图 9: 每个时间步长下, 普通训练 ($T \times D = 4 \times 1$) 和 SFA 训练 ($T \times D = 1 \times 4$) 的网络脉冲发放率 (NSFR)。实验设置与表 5 中的消融实验相同。所有时间步长的 NSFR 之和代表了整个数据集的平均脉冲发放情况: 在普通训练和 SFA 训练中, 每个脉冲神经元平均分别发放 0.96 个和 0.39 个脉冲。




图 10: 二进制脉冲发放会干扰 SNN 的扩展性。(a) MIM 预训练和 SFA 训练的消融实验。在直接使用二进制脉冲发放进行训练时, 即使采用 MIM 预训练, 性能仍然会下降。相比之下, 在使用整数激活函数的 SFA 训练中, MIM 预训练可以有效地扩展 SNN 的性能。(b) MIM-SNN 中有效秩 [105] 的实验结果。

尖峰会影响 MIM-SNN 中编码器部分的特征提取能力。具体而言, 特征提取能力可以通过有效秩来衡量 [76], [105]:

$$\text{Rank}(A) = \exp\left(-\sum_{k=1}^n p \log(p)\right), \quad (29)$$

其中 $p = \frac{\sigma_i^2}{\sum \sigma_i^2}$ 是奇异值的分布。

$\sigma_1, \dots, \sigma_n$ 是对角矩阵 Σ 上的奇异值。它可以通过 SNN 编码器的输出 Z 获得, 其中 $Z = U\Sigma H$ 。较高的有效秩表明提取了丰富的特征信息, 而较低的有效秩则表明提取的特征信息较少。

实验结果如图 10(b) 所示。在采用原始训练方法的 MIM-SNN 中, 有效秩随训练时间的推移而降低 (图 10(b)), 表明特征表示被压缩到低维空间, 这可能会损害模型的泛化能力和任务性能。这可能导致输入样本难以区分、复杂度捕获不足以及性能下降。相比之下, 在采用 SFA 的 MIM-SNN 中, 有效秩在训练过程中逐渐增大并趋于稳定, 表明其特征表示更加鲁棒, 且微调性能更佳。




图 11: 神经形态芯片上脉冲驱动推理的可能实现方式。图中假设 $T = D = 3$ 。异步脉冲驱动没有全局时钟 [10], 整数 D 被转换为 D 个脉冲, 这些脉冲在推理过程中于一个极短的时间窗口内发出。同步脉冲驱动将整数训练中的 T 个时间步扩展到推理过程中的 $T \times D$ 个时间步。

6 讨论与总结

本节讨论了如何在神经形态芯片上执行 SFA 方法和基于 MIM 的预训练 SNN。此外, 我们还总结了 SFA 方法引起的脉冲发放模式变化所产生的深远影响。

6.1 在神经形态芯片上实现 SFA

原始训练和 SFA 训练的脉冲发放模式不同 (图 3)。在 ANN2SNN 和原始直接训练中, 多时间步的脉冲可以被认为是随机的。相比之下, SFA 训练中的脉冲集中且连续。这一点至关重要, 意味着这两种方法在神经形态芯片上的实现机制不同。

图 11 展示了所提出的 SFA 方法如何在神经形态芯片上执行:

i) 同步实现。在这种情况下, 整数

同步地转换为脉冲。具体来说, 由于同步神经形态芯片包含一个全局时钟, T 个时间步被重新扩展为 $T \times D$ 个时间步。在静态视觉任务中, 只有推理期间的时间步发生了变化。在动态视觉任务中, 不同的时间步需要不同的脉冲神经元。Tianjic 在理论上支持这些操作 [6]。

ii) 异步实现。在这种情况下, im-

在芯片上实现“单个时间步扩展 D 次”是指“异步神经形态芯片在极短的时间窗口内发出一系列脉冲 (最多 D 个)。”异步神经形态芯片没有全局时钟, 因此实际上没有时间步的概念 (更多细节请参见 [10] 中的“同步训练和异步部署”部分), 并且不同脉冲神经元之间的脉冲发放是独立的。当有事件输入时, 芯片上的一部分脉冲神经元会被激活, 其余时间它们处于空闲状态。而且, 无需切换脉冲神经元的工作模式即可扩展额外的时间步。Speck [10] 支持这种操作。

我们将对同步或异步实现 SFA 方法的优缺点进行如下讨论:

i) SFA 方法可以通过同步或异步神经形态芯片实现。然而,




图 12: 脉冲稀疏卷积 (SSC) 和普通脉冲卷积 (VSC) 的比较。在神经形态芯片上，当出现脉冲时，地址映射函数会找到需要相加的突触和神经元，然后提取相应的权重来执行加法运算。VSC 和 SSC 的唯一区别在于地址映射函数。在 SSC 中，规定只有当对应于 W (卷积核中心位置) 的位置存在脉冲输入时才执行卷积。VSC 没有此限制。

使用异步芯片实现传统的训练 SNN 较为困难。如图 3 所示，传统的训练 SNN 必须执行所有时间步才能达到脉冲发放的近似状态，因此需要全局同步时钟。相比之下，SFA 训练 SNN 只需完成连续 D 个脉冲的发放，之后脉冲神经元即可休息，无需全局时钟。

ii) 当 D 值较小且脉冲触发频率较低时，异步脉冲驱动的 SFA 实现方式在功耗和延迟方面具有显著优势。风险在于，当 D 值不受限制时，短时间内大量脉冲触发可能导致芯片通信带宽被超过。但这种风险是可控的。

因此，考虑到 SFA 方法的独特特性，显然它更适合异步实现，这对算法驱动型神经形态芯片的设计和开发具有重要意义。另一个值得注意的有趣之处在于，对于 SFA 方法， D 值的增加可能会导致更高的能耗，但能耗增加的程度与具体任务密切相关。例如，将 1×4 调整为 1×8 会导致图像分类任务 (表 1) 的能耗增加显著高于检测任务 (表 2) 和分割任务 (表 3)。

6.2 神经形态芯片天然支持 MIM-SNN 预训练

在神经形态芯片上，脉冲卷积以脉冲驱动的方式执行。

逐事件稀疏处理使神经形态计算能够享受低延迟和低功耗的优势。系统状态会根据每个脉冲输入而改变。接收到脉冲后，SNN 核心通过地址搜索识别相应的权重和目标神经元位置，并相应地更新目标神经元的状态[10]。

脉冲稀疏卷积 (SSC) 旨在解决 MIM-SNN 预训练过程中的信息泄露问题。由于 Vanilla Spike Convolution (VSC) 本身就是一种稀疏计算卷积，因此我们关注 VSC 和 SSC 之间的区别和联系。如图 12 所示，我们观察到，在执行脉冲卷积时，SSC 实际上只比 VSC 多一个判断条件。在 SSC 中，仅当卷积核中心位置 W 处存在脉冲输入时才执行卷积。因此，SSC 始终可以将脉冲特征图中的信息传递到下一层对应的位置。这在需要 MIM 编码器的情况下至关重要，因为大部分信息需要被掩蔽。此外，掩蔽后的图像首先被分割成图像块，SSC 在 E-SpikeFormer 的 MIM 预训练中记录这些掩蔽的位置。然后，SSC 仅在中心卷积核触发脉冲的未掩蔽位置进行操作。

鉴于 VSC 和 SSC 的共通性，我们只需对 VSC 对应的寻址映射函数稍作修改，即可在神经形态芯片上执行 SSC。换句话说，目前的神经形态芯片可以支持基于 MIM 预训练的片上学习。

6.3 总结

在讨论了硬件实现之后，我们在此总结脉冲发放模式对 SNN 的影响。不同的脉冲发放模式，例如 ANN2SNN 和传统训练中的 $\{S[d]\}$ 与 SFA 训练中的 $\{S[d]\}$ ，会导致不同的脉冲分布。这些差异进而影响 SNN 的训练、功耗、性能、扩展性和硬件实现。所有三种训练方法都可以看作是速率编码。我们仍然以图 3 为例来说明它们之间的区别。ANN2SNN 和直接训练必须运行全部十个时间步才能完成速率编码。而 SFA 训练则只需要在前几个时间步发放脉冲。这种虽小但意义重大的设计改进产生了深远的影响：

- i) 降低培训成本 (图 6(b) 和图 7)。当对于静态视觉任务，SFA 只需要一次训练，避免了传统多步直接训练所需的大量训练内存和时间成本。
- ii) 更低的功耗 (图 8 和图 9)。在静态任务中，SFA 方法的推理阶段仅使用一次图像输入，无需像传统直接训练那样重复输入推理。另一方面，SFA 方法获得的脉冲分布的脉冲发放率会随着时间步长逐渐降低。
- iii) 更高的性能 (图 8)。SFA 方法可以生成更清晰的脉冲图。
- iv) 易于扩展 (图 10(b))。整数训练更有可能学习到好的特征。

v) 更适合在异步 neu- 上执行
晶化芯片 (图 11)。SFA 中的推理过程

该方法天然适合部署在异步神经形态芯片上，可以充分体现 SNN 的低功耗和低延迟特性。

7 结论

我们致力于解决脉冲神经网络 (SNN) 和人工神经网络 (ANN) 在性能和训练功耗方面的差距。我们的一项关键贡献在于识别了脉冲神经元中二进制脉冲发放的机制缺陷。为了克服这些局限性，我们提出了一种脉冲发放近似 (SFA) 方法。该方法基于整数训练和脉冲驱动推理，旨在优化脉冲神经元的脉冲发放模式。我们的结果表明，优化脉冲发放模式能够全面提升 SNN 的性能，包括提高训练效率、降低功耗、改善性能、增强可扩展性以及更好地利用神经形态芯片。此外，我们还开发了一种高效的脉冲驱动 Transformer 架构和一种脉冲掩码自编码器，以防止 SNN 在扩展过程中出现性能下降。通过解决大规模 SNN 的训练和性能挑战，我们为神经形态计算的新时代铺平了道路。

致谢

这项工作得到了国家杰出青年科学基金 (62325603)、国家自然科学基金 (62236009、U22A20103、62441606) 的部分资助。

参考

- [1] K. Roy, A. Jaiswal and P. Panda, “基于神经形态计算的脉冲式机器学习”, 《自然》, 第 575 卷, 第 1 期, 第 1-10 页, 2019 年。
- [2] CD 舒曼, SR 库卡尼, M. Parsa, JP 米切尔, B. Kay 等, “神经形态计算算法和应用的机遇”, 《自然计算科学》, 第 2 卷, 第 1 期, 第 179-189 页, 2022 年 10 月 19 日。
- [3] W. Maass, “脉冲神经网络: 第三代神经网络模型”, 《神经网络》, 第 10 卷, 第 9 期, 第 179-189 页, 1659-1671, 1997。
- [4] PA Merolla, JV Arthur, R. Alvarez-Icaza, AS Cassidy, J. Sawada, F. Akopyan, BL Jackson, N. Imam, C. Guo, Y. Nakamura 等人, “具有可扩展通信网络和接口的百万脉冲神经元集成电路”, 《科学》, 第 345 卷, 第 6197 期, 第 668-673 页, 2014 年。
- [5] M. Davies, N. Srinivasa, T.-H. Lin, G. Chinya, Y. Cao, SH Choday, G. Dimou, P. Joshi, N. Imam, S. Jain 等, “Loihi: 具有片上学习功能的神经形态多核处理器”, IEEE Micro, 第 38 卷, 第 1 期, 第 82-99 页, 2018 年。
- [6] J. Pei, L. Deng 等, “基于混合天机芯片架构的通用人工智能”, 《自然》, 第 572 卷, 第 7767 期, 第 179-189 页, 2019 年 106-111 页。
- [7] B. Yin, F. Corradi 和 SM Boht ‘e, “准确高效的时间-“基于自适应脉冲循环神经网络的领域分类”, 《自然机器学习》, 第 3 卷, 第 10 期, 第 905-913 页, 2021 年。
- [8] A. Rao, P. Plank, A. Wild 和 W. Maass, “长期短期“基于脉冲的神经形态硬件中人工智能应用的内存”, 《自然机器学习》, 第 4 卷, 第 5 期, 第 467-479 页, 2022 年。
- [9] P. Duan, Y. Ma, X. Zhou, X. Shi, ZW Wang, T. Huang 和 B. Shi, “Neurozoom: 去噪和超分辨率神经形态事件和尖峰”, IEEE 模式分析与机器学习汇刊, 第 45 卷, 第 12 期, 第 15219-15232 页, 2023 年。
- [10] M. Yao, O. Richter, G. Zhao, N. Qiao, Y. Xing, D. Wang, T. Hu, W. Fang, T. Demirci, M. De Marchi, L. Deng, T. Yan, C. Nielsen, S. Sheik, C. Wu, Y. Tian, B. Xu 和 G. Li, “基于异步感知计算神经形态芯片的基于脉冲的动态计算”, 《自然通讯》, 第 15 卷, 第 1 期, 第 4464 页, 2024 年。
- [11] Y. Hu, H. Tang 和 G. Pan, “脉冲深度残差网络”, IEEE 神经网络与学习系统学报, 第 34 卷, 第 8 期, 第 5200-5205 页, 2023 年。
- [12] N. Rathi, G. Srinivasan, P. Panda 和 K. Roy, “启用深度“具有混合转换和脉冲时间相关反向传播的脉冲神经网络”, 发表于 2020 年国际学习表征会议。
- [13] Y. Hu, Q. Cheng, X. Jiang, G. Pan, “Fast-snn: 快速扣球通过转换量化 ANN 构建神经网络”, IEEE 模式分析与机器学习汇刊, 第 45 卷, 第 12 期, 第 179-189 页, 14 546-14 562, 2023。
- [14] J. Wu, C. Xu, X. Han, D. Zhou, M. Zhang, H. Li 和 KC Tan, “基于深度脉冲神经网络的模式识别的渐进式串联学习”, IEEE 模式分析与机器学习汇刊, 第 44 卷, 第 11 期, 第 7824-7840 页, 2021 年。
- [15] Z. Wang, Y. Fang, J. Cao, Q. Zhang, Z. Wang 和 R. Xu, “Masked”“脉冲变换器”, 载于 IEEE/CVF 国际计算机视觉会议论文集, 2023 年, 第 1761-1771 页。
- [16] Y. Wu, L. Deng, G. Li, J. Zhu, and L. Shi, “Spatio-temporal“反向传播用于训练高性能脉冲神经网络”, 《神经科学前沿》, 第 12 卷, 第 331 页, 2018 年。
- [17] JK Eshraghian, M. Ward, EO Neftci, X. Wang, G. Lenz, G. Dwivedi, M. Bennamoun, DS Jeong 和 WD Lu, “利用深度学习的经验训练脉冲神经网络”, IEEE 会刊, 第 111 卷, 第 9 期, 第 1016-1054 页, 2022 年。
- [18] W. Fang, Z. Yu, Y. Chen, T. Huang, T. Masquelier 和 Y. Tian, “脉冲神经网络中的深度残差学习”, 神经信息处理系统进展, 第 34 卷, 第 21056-21069 页, 2021 年。
- [19] H. Zheng, Y. Wu, L. Deng, Y. Hu 和 G. Li, “深入研究直接训练更大的脉冲神经网络”, 载于 AAAI 人工智能会议论文集, 第 35 卷, 第 12 期, 2021 年, 第 11062-11070 页。
- [20] X.-R. Qiu, Z.-R. Wang, Z. Luan, R.-J. Zhu, X. Wu, M.-L. Zhang, 和 L.-J. Deng, “Vtsnn: 虚拟时间脉冲神经网络”, 神经科学前沿, 第 17 卷, 第 1091097 页, 2023 年。
- [21] M. Yao, G. Zhao, H. Zhang, Y. Hu, L. Deng, Y. Tian, B. Xu 和 G. Li, “注意力脉冲神经网络”, IEEE 模式分析与机器学习汇刊, 第 45 卷, 第 8 期, 第 9393-9410 页, 2023 年。
- [22] H. Deng, R. Zhu, X. Qiu, Y. Duan, M. Zhang, and L.-J. Deng, “基于张量分解的脉冲神经网络注意力模块”, 知识系统, 第 295 卷, 第 111780 页, 2024 年。
- [23] K. Wu, M. Yao, Y. Chou, X. Qiu, R. Yang, B. Xu, and G. Li, “Rsc-snn: 通过随机平滑编码探索脉冲神经网络中对抗鲁棒性和准确性之间的权衡”, 载于第 32 届 ACM 国际多媒体会议论文集, 2024 年, 第 2748-2756 页。
- [24] X. Luo, M. Yao, Y. Chou, B. Xu 和 G. Li, “整数值得用于高性能和节能目标检测的训练和脉冲驱动推理脉冲神经网络”, arXiv 预印本 arXiv:2407.20708, 2024 年。
- [25] W. Fang, Y. Chen, J. Ding, Z. Yu, T. Masquelier, D. Chen, L. Huang, H. Zhou, G. Li 和 Y. Tian, “Spikingjelly: 一个用于基于脉冲的神经的开源机器学习基础设施平台”, 《科学进展》, 第 9 卷, 第 40 期, 第 eadi1480 页, 2023 年。
- [26] Y. Guo, Y. Chen, L. Zhang, X. Liu, Y. Wang, X. Huang, and Z. Ma, “Im-loss: 脉冲神经网络的信息最大化损失”, 神经信息处理系统进展, 第 35 卷, 第 156-166 页, 2022 年。
- [27] L. Deng, Y. Wu, X. Hu, L. Liang, Y. Ding, G. Li, G. Zhao, P. Li, 和 Y. Xie, “重新思考 SNN 和 ANN 之间的性能比较”, 神经网络, 第 121 卷, 第 294-307 页, 2020 年。
- [28] M. Yao, J. Hu, T. Hu, Y. Xu, Z. Zhou, Y. Tian, B. XU 和 G. Li, “Spike-driven transformer v2: 元脉冲神经网络架构启发了下一代神经形态芯片的设计”, 发表于 2024 年第十二届国际学习表征会议。
- [29] M. Yao, J. Hu, Z. Zhou, L. Yuan, Y. Tian, B. Xu 和 G. Li, “Spike-驱动变压器”, 载于《神经信息处理系统进展》, 第 36 卷, 2023 年, 第 64043-64058 页。
- [30] K. He, X. Chen, S. Xie, Y. Li, P. Dollár 和 R. Girshick, “蒙面人”自编码器是可扩展的视觉学习者”, 载于 2022 年 IEEE/CVF 计算机视觉与模式识别会议论文集, 第 16000-16009 页。
- [31] K. Tian, Y. Jiang, C. Lin, L. Wang, Z. Yuan 等, “设计 BERT 用于卷积网络: 稀疏和分层掩码

- 建模”，发表于2022年第十一届国际学习表征会议。
- [32] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “Imagenet: 一个大规模分层图像数据库”，载于2009年IEEE计算机视觉与模式识别会议论文集。IEEE, 2009年, 第248-255页。
- [33] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár and CL Zitnick, “Microsoft coco: 上下文中的常见对象”，载于欧洲计算机视觉会议。Springer, 2014年, 第740-755页。
- [34] B. Zhou, H. Zhao, X. Puig, S. Fidler, A. Barriuso and A. Torralba, “通过ade20k数据集进行场景解析”，载于2017年IEEE计算机视觉与模式识别会议论文集, 第100-110页。633-641。
- [35] X. Wang, Z. Wu, B. Jiang, Z. Bao, L. Zhu, G. Li, Y. Wang, and Y. Tian, “Hardvs: 利用动态视觉传感器重新审视人类活动识别”，载于AAAI人工智能会议论文集, 第38卷, 第6期, 2024年, 第5615-5623页。
- [36] M. Xiao, Q. Meng, Z. Zhang, D. He and Z. Lin, “在线培训”脉冲神经网络的时间演化”，神经信息处理系统进展, 第35卷, 第20717-20730页, 2022年。
- [37] Q. Meng, M. Xiao, S. Yan, Y. Wang, Z. Lin, and Z.-Q. Luo, “面向训练脉冲神经网络的内存和时间高效的反向传播”，载于IEEE/CVF国际计算机视觉会议论文集, 2023年, 第6166-6176页。
- [38] Y. Lin, Y. Hu, S. Ma, D. Yu and G. Li, “重新思考预训练从人工神经网络到神经网络的桥梁”，IEEE神经网络与学习系统汇刊, 第1-14页, 2022年。
- [39] H. Zhang and Y. Zhang, “高效内存可逆脉冲神经网络”，载于AAAI人工智能会议论文集, 第38卷, 第15期, 2024年, 第16759-16767页。
- [40] J. Hu, M. Yao, X. Qiu, Y. Chou, Y. Cai, N. Qiao, Y. Tian, B. Xu, and G. Li, “具有o(1)训练记忆和o(1)推理成本的高性能时间可逆脉冲神经网络”，arXiv预印本arXiv:2405.16466, 2024年。
- [41] SS Chowdhury, N. Rath and K. Roy, “迈向超低“利用时间剪枝实现视觉和序列任务的延迟脉冲神经网络”，载于欧洲计算机视觉会议论文集。Springer出版社, 2022年, 第709-726页。
- [42] Y. Li, T. Geller, Y. Kim and P. Panda, “Seenn: 迈向时间性”“脉冲提前退出神经网络”，载于《神经信息处理系统进展》，第36卷, Curran Associates, Inc., 2023年, 第63327-63342页。
- [43] K. He, X. Zhang, S. Ren and J. Sun, “深度残差学习”用于图像识别”，载于2016年IEEE计算机视觉与模式识别会议论文集, 第770-778页。
- [44] K. He, X. Zhang and S. Ren, “深度残差中的恒等映射”网络”，载于欧洲计算机视觉会议论文集。Springer出版社, 2016年, 第630-650页。
- [45] Y. Hu, L. Deng, Y. Wu, M. Yao, and G. Li, “推进扣球“神经网络迈向深度残差学习”，IEEE神经网络与学习系统汇刊, 第1-15页, 2024年。
- [46] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, AN Gomez, Ł. Kaiser and I. Polosukhin, “你只需要关注”，神经信息处理系统进展, 第30卷, 2017年。
- [47] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly等人, “一张图片胜过16x16个字: 用于大规模图像识别的Transformers”，发表于2020年国际学习表征会议。
- [48] J. Zhang, L. Tang, Z. Yu, J. Lu and T. Huang, “尖峰转换器: “用于脉冲相机的单目深度估计”，载于欧洲计算机视觉会议论文集。Springer, 2022年, 第34-52页。
- [49] Q. Wang, T. Zhang, M. Han, Y. Wang, D. Zhang and B. Xu, “Com-plex动态神经元改进的脉冲变换网络用于高效的自动语音识别”，载于AAAI人工智能会议论文集, 第37卷, 第1期, 2023年, 第102-109页。
- [50] Z. Zhou, Y. Zhu, C. He, Y. Wang, S. Yan, Y. Tian and L. Yuan, “Spikformer: 当脉冲神经网络遇到Transformer”，在2023年第十一届国际学习表征会议上。
- [51] W. Yu, M. Luo, P. Zhou, C. Si, Y. Zhou, X. Wang, J. Feng, and S. Yan, “Metaformer实际上就是视觉所需的”，载于2022年IEEE/CVF计算机视觉与模式识别会议论文集, 第10819-10829页。
- [52] Y. Chou, M. Yao, K. Wang, Y. Pan, R.-J. Zhu, J. Wu, Y. Zhong, Y. Qiao, B. XU and G. Li, “MetaLA: 统一最优线性“softmax注意力的近似方法”，发表于2024年第三十八届神经信息处理系统年会。[在线]。网址: <https://openreview.net/forum?id=Y8YVCOMepz>
- [53] J.德夫林, M.-W. Chang, K. Lee and K. Toutanova, “伯特: 预“用于语言理解的深度双向Transformer的训练”，arXiv预印本arXiv:1810.04805, 2018年。
- [54] H. Bao, L. Dong, S. Piao and F. Wei, “Beit: 图像Transformer的BERT预训练”，arXiv预印本arXiv:2106.08254, 2021年。[55] J. Zhou, C. Wei, H. Wang, W. Shen, C. Ye, A. Villa and T. Kong, “使用在线分词器进行图像BERT预训练”，发表于2021年国际学习表征会议。
- [56] C. Wei, H. Fan, S. Xie, C.-Y. Wu, A. Yuille and C. Feichtenhofer, “用于自监督视觉预训练的掩码特征预测”，载于IEEE/CVF计算机视觉与模式识别会议论文集, 2022年, 第14668-14678页。
- [57] P. Gao, T. Ma, H. Li, Z. Lin, J. Dai and Y. Qiao, “Mcmoe: “掩码卷积与掩码自编码器相遇”，载于《神经信息处理系统进展》，S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho and A. Oh编辑, 第35卷, Curran Associates, Inc., 2022年, 第35632-35644页。
- [58] S. Woo, S. Debnath, R. Hu, X. Chen, Z. Liu, IS Kweon and S. Xie, “Convnext v2: 与掩码自编码器共同设计和扩展卷积神经网络”，载于IEEE/CVF计算机视觉与模式识别会议论文集, 2023年6月, 第16133-16142页。
- [59] EO Neftci, H. Mostafa and F. Zenke, “替代梯度“脉冲神经网络中的学习: 将基于梯度的优化能力引入脉冲神经网络”，IEEE信号处理杂志, 第36卷, 第6期, 第51-63页, 2019年。
- [60] W. Gerstner, WM Kistler, R. Naud and L. Paninski, 《神经元动力学: 从单个神经元到网络和认知模型》。剑桥大学出版社, 2014年。
- [61] Indiveri G, Linares-Barranco B, Hamilton TJ, AV. 沙伊克, R. Etienne-Cummings, T. Delbruck, S.-C. Liu, P. Dudek, P. Häfliger, S. Renaud等人, “神经形态硅神经元电路”，神经科学前沿, 第5卷, 第73页, 2011年。
- [62] W. Fang, Z. Yu, Z. Zhou, D. Chen, Y. Chen, Z. Ma, T. Masquelier, and Y. Tian, “具有高效率和学习长期依赖性能力的并行脉冲神经元”，载于《神经信息处理系统进展》，第36卷, 2023年, 第53674-53687页。
- [63] W. Ponghiran and K. Roy, “带im-的脉冲神经网络”在AAAI人工智能会议论文集, 第36卷, 第7期, 2022年, 第8001-8008页中证明了序列学习的固有递归动态。
- [64] G. Shen, D. Zhao, T. Li, J. Li and Y. Zeng, “传统SNN是否有效? ”真的高效吗? 来自网络量化的视角”，arXiv预印本arXiv:2311.10802, 2023年。
- [65] Z. Wu, H. Zhang, Y. Lin, G. Li, M. Wang, and Y. Tang, “Liaf-net: “用于轻量级和高效时空信息处理的泄漏积分和模拟火网络”，IEEE神经网络与学习系统汇刊, 第33卷, 第11期, 第6249-6262页, 2021年。
- [66] Y. Wu, L. Deng, G. Li, J. Zhu, Y. Xie, and L. Shi, “Direct training “对于脉冲神经网络: 更快、更大、更好”，载于AAAI人工智能会议论文集, 第33卷, 第01期, 2019年, 第1311-1318页。
- [67] N. Rath and K. Roy, “Diet-snn: 一种低延迟脉冲神经网络”具有直接输入编码、泄漏和阈值优化的网络”，IEEE神经网络与学习系统汇刊, 第34卷, 第6期, 第3174-3182页, 2023年。
- [68] W. Wei, M. Zhang, J. Zhang, A. Belatreche, J. Wu, Z. Xu, X. Qiu, H. Chen, Y. Yang and H. Li, “脉冲神经网络的事件驱动学习”，arXiv预印本arXiv:2403.00270, 2024年。
- [69] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov and L.-C. Chen, “Mobilenetv2: 反向残差和线性瓶颈”，载于2018年IEEE计算机视觉与模式识别会议论文集, 第4510-4520页。
- [70] S. Ioffe and C. Szegedy, “批量归一化: 加速深度运算”通过减少内部协变量偏移进行网络训练”，国际机器学习会议论文集。PMLR, 2015年, 第448-456页。
- [71] F. Chollet, “Xception: 具有深度可分离性的深度学习”卷积”，载于2017年IEEE计算机视觉与模式识别会议论文集, 第1251-1258页。
- [72] H. Cai, C. Gan and S. Han, “Efficientvit: 用于高分辨率低计算视觉识别的增强型线性注意力机制”，arXiv预印本arXiv:2205.14756, 2022。

- [73] SN Wadekar and A. Chaurasia, “Mobilevitv3: 移动友好“视觉转换器具有简单有效的局部、全局和输入特征融合”, arXiv 预印本 arXiv:2209.15159, 2022 年。
- [74] J. Zhang, X. Li, J. Li, L. Liu, Z. Xue, B. Zhang, Z. Jiang, T. Huang, Y. Wang 和 C. Wang, “重新思考移动块以实现高效的基于注意力的模型”, 载于 IEEE/CVF 国际计算机视觉会议论文集, 2023 年, 第 1389-1400 页。
- [75] H. Touvron, M. Cord, M. Douze, F. Massa, A. Sablayrolles 和 H. Jégou, “通过注意力训练数据高效的图像转换器和蒸馏”, 国际机器学习会议。PMLR, 2021, 第 10347-10357 页。
- [76] 张强、王勇、王勇, “口罩的重要性: 展望未来掩码自编码器的理论理解”, 神经信息处理系统进展, 第 35 卷, 第 27127-27139 页, 2022 年。
- [77] 王伟, 谢鄂, 李晓, D.-P. 范、宋、梁、鲁、罗鹏、和 L. Shao, “Pyramid vision transformer: 一种无需卷积即可进行密集预测的多功能骨干网络”, 载于 2021 年 IEEE/CVF 国际计算机视觉会议论文集, 第 177 页, 568-578。
- [78] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, S. Lin 和 B. Guo, “Swin transformer: 使用移位窗口的分层视觉转换器”, 载于 2021 年 IEEE/CVF 国际计算机视觉会议论文集, 第 10012-10022 页。
- [79] W. Yu, C. Si, P. Zhou, M. Luo, Y. Zhou, J. Feng, S. Yan, and X. Wang, “视觉的 Metaformer 基线”, IEEE 模式分析与机器学习汇刊, 2023 年。
- [80] 袁莉, 陈勇, 王涛, 于伟, 史勇, 姜志华, 费永 Tay, J. Feng 和 S. Yan, “Tokens-to-token vit: 在 ImageNet 上从零开始训练视觉 Transformer”, 载于 IEEE/CVF 国际计算机视觉会议论文集, 2021 年, 第 170 页, 558-567。
- [81] X. Ding, X. Zhang, J. Han 和 G. Ding, “扩展你的内核”到 31x31: 重新审视 cnns 中的大内核设计”, 载于 2022 年 IEEE/CVF 计算机视觉与模式识别会议论文集, 第 11963-11975 页。
- [82] J. Yang, C. Li, P. Zhang, X. Dai, B. Xiao, L. Yuan 和 J. Gao, “视觉转换器中局部-全局交互的焦点自注意力”, arXiv 预印本 arXiv:2107.00641, 2021。
- [83] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell 和 S. Xie, “面向 2020 年代的卷积神经网络”, 载于 2022 年 IEEE/CVF 计算机视觉与模式识别会议论文集, 第 179 页, 11 976-11 986。
- [84] A. 斯里尼瓦斯, T.-Y. Lin, N. Parmar, J. Shlens, P. Abbeel 和 A. Vaswani, “视觉识别的瓶颈变压器”在 IEEE/CVF 计算机视觉与模式识别会议论文集, 2021 年, 第 16519-16529 页。
- [85] W. Wang, W. Chen, Q. Qiu, L. Chen, B. Wu, B. Lin, X. He 和 W. Liu, “Crossformer++: 一种基于跨尺度注意力的多功能视觉转换器”, IEEE 模式分析与机器学习汇刊, 第 46 卷, 第 5 期, 第 3123-3136 页, 2024 年。
- [86] T. Bu, W. Fang, J. Ding, P. Dai, Z. Yu, and T. Huang, “Opti-“用于高精度和超低延迟脉冲神经网络的 mal ann-snn 转换”, 发表于 2021 年国际学习表征会议。
- [87] Y. Hu, Q. Cheng, X. Jiang, G. Pan, “Fast-snn: 快速扣球通过转换量化 ANN 构建神经网络”, IEEE 模式分析与机器学习汇刊, 第 45 卷, 第 12 期, 第 179-189 页, 14 546-14 562, 2023。
- [88] 王正、张勇、连世行、崔晓、严荣、唐华, 《走向“具有两阶段优化的高精度、低延迟脉冲神经网络”, IEEE 神经网络与学习系统汇刊, 第 1-15 页, 2023 年。
- [89] S. Deng, Y. Li, S. Zhang 和 S. Gu, “时间高效训练”“通过梯度重加权实现脉冲神经网络”, 发表于 2022 年国际学习表征会议。
- [90] Q. Meng, M. Xiao, S. Yan, Y. Wang, Z. Lin, and Z.-Q. Luo, “通过对脉冲表示进行微分来训练高性能低延迟脉冲神经网络”, 载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 2022 年, 第 12444-12453 页。
- [91] X. Qiu, R.-J. Zhu, Y. Chou, Z. Wang, L.-j. Deng 和 G. Li, “门控“用于训练高性能和高效脉冲神经网络的注意力编码”, 载于 AAAI 人工智能会议论文集, 第 38 卷, 第 1 期, 2024 年, 第 601-610 页。
- [92] Z. Zhou, K. Che, W. Fang, K. Tian, Y. Zhu, S. Yan, Y. Tian 和 L. Yuan, “Spikformerv2: 使用 SNN 门票加入 ImageNet 高精度俱乐部”, arXiv 预印本 arXiv:2401.02020, 2024 年。
- [93] H. Li, H. Liu, X. Ji, G. Li 和 L. Shi, “Cifar10-dvs: 一个事件-用于对象分类的流数据集”, 《神经科学前沿》, 第 11 卷, 第 309 页, 2017 年。
- [94] X. Zhu, W. Su, L. Lu, B. Li, X. Wang 和 J. Dai, “可变形 DETR: 用于端到端目标检测的可变形变换器”, 在 2020 年国际学习表征会议上。
- [95] S. Kim, S. Park, B. Na 和 S. Yoon, “Spiking-yolo: 脉冲神经网络用于节能目标检测的网络”, AAAI 人工智能会议论文集, 第 34 卷, 第 11270-11277 页, 2020 年。
- [96] Y. Li, X. He, Y. Dong, Q. Kong 和 Y. Zeng, “尖峰校准: “用于目标检测和分割的脉冲神经网络的快速准确转换”, arXiv 预印本 arXiv:2207.02702, 2022 年。
- [97] H. Zhang, Y. Li, B. He, X. Fan, Y. Wang 和 Y. Zhang, “直接训练高性能脉冲神经网络用于物体识别和检测”, 《神经科学前沿》, 第 17 卷, 第 17 页, 1229951, 2023。
- [98] Q. Su, Y. Chou, Y. Hu, J. Li, S. Mei, Z. Zhang 和 G. Li, “深层“直接训练脉冲神经网络用于目标检测”, 载于 IEEE/CVF 国际计算机视觉会议论文集, 2023 年, 第 6555-6565 页。
- [99] W. Wang, J. Dai, Z. Chen, Z. Huang, Z. Li, X. Zhu, X. Hu, T. Lu, L. Lu, H. Li 等人, “Internimage: 利用可变形卷积探索大规模视觉基础模型”, 载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 2023 年, 第 14408-14419 页。
- [100] H. Zhang, C. Wu, Z. Zhang, Y. Zhu, H. Lin, Z. Zhang, Y. Sun, T. He, J. Mueller, R. Manmatha 等人, “Resnest: 分裂注意力网络”, 载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 2022 年, 第 2736-2746 页。
- [101] C. Feichtenhofer, H. Fan, J. Malik 和 K. He, “慢快网络”用于视频识别”, 载于 2019 年 IEEE/CVF 国际计算机视觉会议论文集, 第 6202-6211 页。
- [102] Z. Wang, Q. She 和 A. Smolic, “Action-net: 多路径激发”用于动作识别”, 载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 2021 年, 第 13214-13223 页。
- [103] G. Bertasius, H. Wang 和 L. Torresani, “时空注意力“视频理解所需的一切?”在国际机器学习会议上发表。PMLR, 2021, 第 4 页。
- [104] M. Yao, J. Hu, G. Zhao, Y. Wang, Z. Zhang, B. Xu 和 G. Li, “脉冲神经网络的固有冗余”, 载于 IEEE/CVF 国际计算机视觉会议论文集, 2023 年, 第 16924-16934 页。
- [105] O. Roy 和 M. Vetterli, “有效秩: 有效维度的度量”, 2007 年第 15 届欧洲信号处理会议。IEEE, 2007 年, 第 606-610 页。